



МІНІСТЕРСТВО ОСВІТИ І НАУКИ УКРАЇНИ
НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ
УКРАЇНИ
«КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ
ІМЕНІ ІГОРЯ СІКОРСЬКОГО»
ФАКУЛЬТЕТ БІОМЕДИЧНОЇ ІНЖЕНЕРІЇ
КАФЕДРА БІОМЕДИЧНОЇ КІБЕРНЕТИКИ

РОЗРАХУНКОВО-ГРАФІЧНА РОБОТА

з дисципліни «Нечіткі моделі в медицині»

на тему: «Класифікатор у вигляді багатошарового персептрону,
сформованого на основі методу пошуку у вигляді генетичного алгоритму.»

Варіант №13

Виконав:

студент гр. БС-81
Погребенко В.О.

Перевірив:

доц. каф. БМК
Добровська Л.М.

Зараховано від ____ . ____ . ____

(підпис викладача)

Київ-2020

ЗМІСТ

ВСТУП	3
АНОТАЦІЯ	4
ОСНОВНА ЧАСТИНА.....	7
Методи виконання завдання	7
Розділ 1. Дані для завдання.....	8
Розділ 2. Етапи виконання завдання	10
2.1 Створення багатошарового персептрону.	10
2.2 Реалізація генетичного алгоритму	10
Розділ 3. Остаточний результат	12
ВИСНОВКИ.....	15
СПИСОК ВИКОРИСТАНИХ ДЖЕРЕЛ.....	16
ДОДАТОК А.....	18
ДОДАТОК Б	20

ВСТУП

Актуальність розрахунково-графічної роботи роботи полягає у створенні класифікатору у вигляді багат шарового персептрону, сформованого на основі методу пошуку у вигляді генетичного алгоритму. Отриманий багат шаровий персептрон буде за допомогою зібраних даних з пацієнта таких як: нахил тазу, поперековий кут лордозу, етс буде визначати, чи є аномалії хребту у пацієнта.

Так як біль у попереку є надзвичайно поширеним явищем, симптоми та вираженість болю в попереку дуже різняться. Вони можуть бути спричинені різноманітними проблемами з будь-якими частинами складної, взаємопов'язаної мережі спинномозкових м'язів, нервів, кісток, дисків або сухожилів в поперековому відділі хребта. [1]

Таким чином, хоча обстеження можуть бути у нормі згідно з прийнятими значеннями, існує можливість що проблеми викликані комплексом змін, що не виходять за границі норми, та які важко діагностувати звичайній людині. Тому, класифікація аномальності результатів завдяки MLP є актуальним та важливим завданням для дослідження пацієнтів. [2]

Але для того, щоб сформувати оптимальний MLP, необхідно знайти найкращу кількість слоїв прихованих нейронів, функцію активації, етс, що майже неможливо зробити «вручну». Тому для пошуку формування оптимального MLP буде використаний генетичний алгоритм, що дозволить знайти рішення для цієї задачі.

У результаті, буде сформований MLP на основі методу пошуку у вигляді генетичного алгоритму, що дозволить класифікувати результати досліджень стану хребта пацієнтів.

АНОТАЦІЯ

Розрахунково-графічну роботу виконав Погребенко Василь Олександрович, студент 3 курсу, групи БС-81, кафедри біомедичної кібернетики, факультету біомедичної інженерії НТУУ «КПІ ім. Ігоря Сікорського».

Тема розрахунково-графічної роботи: Класифікатор у вигляді багат шарового персептрону, сформованого на основі методу пошуку у вигляді генетичного алгоритму.

Структура і обсяг роботи: розрахунково-графічна робота складається із вступу, основної частини, висновків, списку використаної літератури із трьох джерел, та двох додатків. Загальний обсяг розрахунково-графічної роботи становить 31 сторінку, основного тексту (без додатків) – 17 сторінок, ілюстрацій – 8, таблиць - 1.

АННОТАЦИЯ

Расчетно-графическую работу выполнил Погребенко Василий Александрович, студент 3 курса, группы БС-81, кафедры биомедицинской кибернетики, факультета биомедицинской инженерии НТУУ «КПИ им. Игоря Сикорского».

Тема расчетно-графической работы: Классификатор в виде многослойного персептрона, сформированного на основе метода поиска в виде генетического алгоритма.

Структура и объем работы: расчетно-графическая работа состоит из введения, основной части, заключения, списка использованной литературы из трех источников, и двух приложений. Общий объем расчетно-графической работы составляет 31 страницу, основного текста (без приложений) - 17 страниц, иллюстраций – 8, таблиц - 1.

ABSTRACT

The calculation and graphic work was performed by Pohrebenko Vasyl, 3rd year student, group BS-81, Department of Biomedical Cybernetics, Faculty of Biomedical Engineering, NTUU "KPI named after Igor Sikorsky. "

The topic of calculation and graphic work: Classifier in the form of a multilayer perceptron, formed on the basis of the search method in the form of a genetic algorithm.

Structure and scope of work: calculation and graphic work consists of the introduction, the main part, conclusion, the list of references from three sources, and two applications. The total amount of calculation and graphic work consists of 31 pages of the main text (without attachments) - 17 pages, illustrations – 8, tables - 1.

ОСНОВНА ЧАСТИНА

Методи виконання завдання

У завданні використовується багатошаровий персептрон (MLP) (використовується бібліотека з python sklearn), та генетичний алгоритм

Багатошаровий персептрон (MLP) - це вид нейронної мережі, що складається щонайменше з трьох шарів вузлів: вхідного шару, прихованого шару та вихідного шару. За винятком вхідних вузлів, кожен вузол є нейроном, який використовує нелінійну функцію активації. MLP використовує контрольовану техніку навчання, яка називається зворотним розповсюдженням для навчання (backpropagation). Його багатошаровість і нелінійна активація відрізняють MLP від лінійного персептрона. Він може розрізняти дані, які не можна лінійно розділити.

Генетичний алгоритм - це евристичний алгоритм пошуку що принципом дії нагадує процес природного. Генетичні алгоритми зазвичай використовуються для рішення задач щодо оптимізації та пошуку, що використовує мутації, кросовери, etc

Виконання завдання поділяється на 3 розділи.

Розділ 1. Дані для завдання

Для завдання використовується «Lower Back Pain Symptoms Dataset», що містить данні про дані досліджень пацієнтів їх зібрані фізичні дані / дані стану хребта. Повний сет даних приведений у додатку А.

Col1	Col2	Col3	Col4	Col5	Col6	Col7	Col8
63.0278175	22.55258597	39.60911701	40.39.05695098	10.06099147	25.01537822	28.68.83202098	22.21848205
50.09219357	46.69.29700807	24.65287791	44.31123813	44.49.71285934	9.652074879	28.317406	40.0
40.25019968	13.92190658	25.1249496	26.53.43292815	15.86433612	37.16593387	37.45.36675362	10.75561143
29.03834896	34.43.79019026	13.5337531	42.69081398	30.36.68635286	5.010884121	41.9487509	31.
49.70660953	13.04097405	31.33450009	36.31.23238734	17.71581923	15.5	13.516568	48.91555137
19.96455616	40.26379358	28.53.5721702	20.46082824	33.1	33.1113419	57.30022656	24.1888846
46.99999999	33.44.31890674	12.53799164	36.098763	31.7	62.82408162	20.26250706	54.55242267
41.20.26250706	54.55242267	41.20.26250706	54.55242267	41.20.26250706	54.55242267	41.20.26250706	54.55242267

Рис. 1. Вміст файлу з зібраними даними

```
0      Abnormal
1      Abnormal
2      Abnormal
3      Abnormal
4      Abnormal
...
305     Normal
306     Normal
307     Normal
308     Normal
309     Normal
Name: Class att, Length: 310, dtype: object
```

Рис. 2. Колонка, що описує, чи є дані аномальними.

Attribute name	type
Col1	pelvic_incidence
Col2	pelvic_tilt
Col3	lumbar_lordosis_angle
Col4	sacral_slope
Col5	pelvic_radius
Col6	degree_spondylolisthesis
Col7	pelvic_slope
Col8	Direct_tilt
Col9	thoracic_slope
Col10	cervical_tilt
Col11	sacrum_angle
Col12	scoliosis_slope
Class_att	Attribute Class
Unnamed	dummy Column

Табл. 1. Опис даних колонок.

Тобто, кожна колонка містить певний параметр. Наприклад, pelvic incidence у перекладі – охоплення тазу, pelvic_tilt – нахил тазу, etc. [3]

Розділ 2. Етапи виконання завдання

Повний код програми можна побачити у додатку Б. Під час виконання були виділені наступні етапи:

2.1 Створення багатошарового персептрону.

За допомогою бібліотеки `sklearn` був створений MLP, що класифікує результати відносно вимог, проте його точність (з більшістю параметрів за замовчуванням) коливалась від 70% до 80%, тому для підняття його ефективності потрібно розробити генетичний алгоритм, що сформував би оптимальний багатошаровий персептрон.

2.2 Реалізація генетичного алгоритму

Був реалізований генетичний алгоритм для формування оптимального персептрону. У ході розробки були прийняті наступні рішення:

1. Кількість поколінь, та популяція кожного покоління.

Неможливо точно сказати оптимальну кількість цих параметрів, і їх значення, зазвичай, підбираються практичним шляхом. Але існують рекомендації для перших кроків дослідження.

Розмір популяції:

Менший розмір популяції забезпечує швидшу конвергенцію (стан, коли кожна особина в популяції однакова, або майже однакова, і еволюція припинилась), але тоді алгоритм може потрапити до *локального* оптимуму, що не є гарним, але не найкращим варіантом. Зворотне стосується великої чисельності популяції. [4]

Таким чином для початку рекомендують обирати або число що дорівнює:

$$X * D$$

X – будь яке число від 5 до 10

D – кількість вимірів, у нашому випадку - кількість вхідних параметрів налаштувань.[5],

Або

$$(1.5 \text{ або } 2) * G$$

X – будь яке число від 1.5 до 2

G – кількість генів (можливих опцій налаштувань) [6][7].

У нашому випадку за першим засобом було отримано: $6 * 10 = 60$, а за другим: $2 * 26 = 52$. Був обраний перший варіант для забезпечення різноманітності поколінь – **60**.

Кількість поколінь:

Як і у випадку з популяцією, кількість поколінь зазвичай підбирається практичним шляхом, проте рекомендується обирати число збалансоване з кількістю поколінь, наприклад 60\50, 50\60, щоб як можна менша кількість останніх поколінь були у стані конвергенції, та не виконувалась «пуста» робота. Для даної задачі була обрана кількість поколінь - **50** [8]

2. Шанс мутації

Шанс мутації також залежить від задачі та її стадії. Зазвичай, під час перших запусків та початкового пошуку її ставлять досить високою, поступово знижуючи [9]

Крім того, була введено авторське поняття «радикальна мутація». Вона використовується для того, щоб у випадку, якщо алгоритм потрапить до *локального* оптимуму, у нього була можливість вийти зі стану конвергенції, та знайти нові, більш оптимальні налаштування. Ця мутація, на відміну від

звичайної, сильно змінює певний параметр, та може кардинально змінити роботи MLP. Це рішення дало приріст ефективності для розроблюваного генетичного алгоритму.

Для задачі що була поставлена у РГР був обраний шанс мутації **0.2**, та шанс того, що ця мутація стане радикальною – **0.1** (тобто загальний шанс радикальної мутації = $0.2 * 0.1$)

Розділ 3. Остаточний результат

В результаті виконання програми було збережено 3 найкращі MLP (параметер що відповідає за кількість збережених MLP можна налаштувати разом з усіма іншими, див. рис. 3).

Ці MLP мають високу точність класифікації, та найбільш оптимізовані для заданої задачі. (рис. 5).

У випадку їх необхідності, модель можна бути прочитати з диску, та використовувати для класифікації (рис. 6).

```
# Number of networks to save to disk
SAVE_NET_NUM = 3
# % of networks to keep from previous generation
# There is no crossover chance, best parents will be kept with their childrens in purpose to avoid degenerating process
RETAIN = 0.3
# Chance of mutation
MUTATE_CHANCE = 0.2
# Chance that during mutation int\tuple variables will be changed to some value from param list
# Used to add variance to algorithm and delay convergence (sometimes it's unnecessary, but anyway).
RADICAL_MUTATE_CHANCE = 0.1

# Number of generations to run
GENERATIONS = 50
# Number of networks in each population
POPULATION = 60
```

Рис. 3. Можливі налаштування програми

```
#####
***Doing generation 9 of 50***
100%|#####| 60/60 [00:25<00:00, 2.391t/s]
Generation top average: 83.69%
#####
***Doing generation 10 of 50***
100%|#####| 60/60 [00:38<00:00, 1.571t/s]
Generation top average: 83.76%
#####
***Doing generation 11 of 50***
100%|#####| 60/60 [00:27<00:00, 2.151t/s]
Generation top average: 83.76%
#####
***Doing generation 12 of 50***
100%|#####| 60/60 [00:30<00:00, 1.991t/s]
Generation top average: 84.26%
#####
```

Рис. 4. Процес роботи програми

```
#####
#####
{'hidden_layer_sizes': 12, 'max_iter': 9000, 'alpha': 1e-05, 'solver': 'lbfgs', 'activation': 'relu', 'tol': 0.001}
Network accuracy: 88.46%
{'hidden_layer_sizes': 12, 'max_iter': 6000, 'alpha': 0.0001, 'solver': 'lbfgs', 'activation': 'relu', 'tol': 0.001}
Network accuracy: 87.18%
{'hidden_layer_sizes': (50, 50), 'max_iter': 9000, 'alpha': 1e-05, 'solver': 'sgd', 'activation': 'tanh', 'tol': 0.001}
Network accuracy: 87.18%
```

Рис. 5. Оптимальні налаштування MLP що знайдені за допомогою генетичного алгоритму




Рис. 6. Збереженні MLP

Прочитаємо записаний MLP, дамо йому 2 записи. Перший – аномальний, а другий – нормальний (рис. 7, рис. 8, рис. 9)

	Col1	Col2	Col3	Col4	Col5	Col6	Col7	Col8	Col9	Col10	Col11	Col12
0	9.9999999e+06	22.552586	39.609117	1.000000e+07	-0.25440	9.999999e+06	12.566100	14.5386	15.30468	-28.658501	43.512300	9.999999e+06
1	4.623640e+01	10.062770	37.000000	3.617363e+01	128.06362	-5.100053e+00	0.860784	9.5912	15.17690	16.499890	-22.420021	4.020610e+01

Рис. 7. Тестові дані

```
classifier = None

with open("networks/classifier_2021-01-08_acc0.8846153846153846.pkl", 'rb') as fid:
    classifier = pickle.load(fid)
```

Рис. 8. Завантаження класифікатора

```
1 116230764762 10764  
['Abnormal' 'Normal']
```

Рис. 9. Результат роботи завантаженого класифікатора

Як можна побачити за рис. 9, класифікатор відпрацював вірно. Повний код тесту можна побачити у додатку Б.

ВИСНОВКИ

В розрахунково-графічній роботі був створений класифікатор у вигляді багатошарового персептрону, сформованого на основі методу пошуку у вигляді генетичного алгоритму

Під час виконання завдання була використана мова програмування Python (з використанням ООП), та також використані деякі бібліотеки для створення MLP, як sklearn, що дозволило спростити та пришвидшити розробку і реалізувати завдання. Весь код було задокументовано для простішого його сприйняття.

В результаті роботи було отримано класифікатор у вигляді багатошарового персептрону, що був сформований завдяки генетичного алгоритму, що може за даними стану хребта (та тіла в загалом) пацієнта виявити, чи є аномалії у його показниках.

Так як алгоритм виконується досить довго (20-25 хв при популяції в 60 мереж та 50 поколіннях на машині з процесором: Intel® Core™ i5-4590, та 16gb RAM), для покращення програми у майбутньому можна додати паралельні обчислення за допомогою модуля multiprocessing. Крім того, ще можна продумати і покращити механізм мутацій, що дозволить формувати кращі для MLP.

СПИСОК ВИКОРИСТАНИХ ДЖЕРЕЛ

1. Lower Back Pain Symptoms Dataset [Електронний ресурс] – Режим доступу до ресурсу: <https://www.kaggle.com/sammy123/lower-back-pain-symptoms-dataset>
2. What is causing this pain in my back? [Електронний ресурс] – Режим доступу до ресурсу: <https://www.medicalnewstoday.com/articles/172943#diagnosis>
3. An Exploratory Data Analysis on Lower Back Pain [Електронний ресурс] – Режим доступу до ресурсу: <https://towardsdatascience.com/an-exploratory-data-analysis-on-lower-back-pain-6283d0b0123>
4. An Investigation on Genetic Algorithm Parameters [Електронний ресурс] – Режим доступу до ресурсу: <http://sarmady.com/siamak/papers/genetic-algorithm.pdf>
5. What is the optimal/recommended population size for differential evolution? [Електронний ресурс] – Режим доступу до ресурсу: https://www.researchgate.net/post/What_is_the_optimal_recommended_population_size_for_differential_evolution2
6. Vose, M.: Modeling simple genetic algorithms. *Evol. Comput.* 3(4), 453–472 (1996)
7. How to calculate the Crossover, Mutation rate and population size for Genetic algorithm? [Електронний ресурс] – Режим доступу до ресурсу: <https://www.researchgate.net/post/How-to-calculate-the-Crossover-Mutation-rate-and-population-size-for-Genetic-algorithm>
8. What is the optimal/recommended population size for differential evolution? [Електронний ресурс] – Режим доступу до ресурсу: https://www.researchgate.net/post/What_is_the_optimal_recommended_population_size_for_differential_evolution2

9. Why is the mutation rate in genetic algorithms very small? [Электронный ресурс] – Режим доступа до ресурсу: <https://www.researchgate.net/post/Why-is-the-mutation-rate-in-genetic-algorithms-very-small>

ДОДАТОК А

Через занадто великий розмір даних, у додатку буде приведена тільки їх частина.

Всі дані можна знайти за посиланням: <https://www.kaggle.com/sammy123/lower-back-pain-symptoms-dataset>

Col1	Col2	Col3	Col4	Col5	Col6	Col7	Col8	Col9	Col10	Col11	Col12	Class_att
63.02782	22.55259	39.60912	40.47523	98.67292	-0.2544	0.744503	12.5661	14.5386	15.30468	-28.6585	43.5123	Abnormal
39.05695	10.06099	25.01538	28.99596	114.4054	4.564259	0.415186	12.8874	17.5323	16.78486	-25.5306	16.1102	Abnormal
68.83202	22.21848	50.09219	46.61354	105.9851	-3.53032	0.474889	26.8343	17.4861	16.65897	-29.0319	19.2221	Abnormal
69.29701	24.65288	44.31124	44.64413	101.8685	11.21152	0.369345	23.5603	12.7074	11.42447	-30.4702	18.8329	Abnormal
49.71286	9.652075	28.31741	40.06078	108.1687	7.918501	0.54336	35.494	15.9546	8.87237	-16.3784	24.9171	Abnormal
40.2502	13.92191	25.12495	26.32829	130.3279	2.230652	0.789993	29.323	12.0036	10.40462	-1.51221	9.6548	Abnormal
53.43293	15.86434	37.16593	37.56859	120.5675	5.988551	0.19892	13.8514	10.7146	11.37832	-20.5104	25.9477	Abnormal
45.36675	10.75561	29.03835	34.61114	117.2701	-10.6759	0.131973	28.8165	7.7676	7.60961	-25.1115	26.3543	Abnormal
43.79019	13.53375	42.69081	30.25644	125.0029	13.28902	0.190408	22.7085	11.4234	10.59188	-20.0201	40.0276	Abnormal
36.68635	5.010884	41.94875	31.67547	84.24142	0.664437	0.3677	26.2011	8.738	14.91416	-1.7021	21.432	Abnormal
49.70661	13.04097	31.3345	36.66564	108.6483	-7.82599	0.68801	31.3502	16.5097	15.17645	-0.50213	18.3437	Abnormal
31.23239	17.71582	15.5	13.51657	120.0554	0.499751	0.608343	21.4356	9.2589	14.76412	-21.7246	36.4449	Abnormal
48.91555	19.96456	40.26379	28.951	119.3214	8.028895	0.139478	32.7916	7.2049	8.61882	-1.21554	27.3713	Abnormal
53.57217	20.46083	33.1	33.11134	110.9667	7.044803	0.081931	15.058	12.8127	12.00109	-1.73412	15.6205	Abnormal
57.30023	24.18888	47	33.11134	116.8066	5.766947	0.416722	16.5158	18.6222	8.51898	-33.4413	13.2498	Abnormal
44.31891	12.53799	36.09876	31.78092	124.1158	5.415825	0.664041	9.5021	19.1756	7.25707	-32.8939	19.5695	Abnormal
63.83498	20.36251	54.55243	43.47247	112.3095	-0.62253	0.560675	10.769	16.8116	11.41344	2.676002	17.3859	Abnormal
31.27601	3.144669	32.563	28.13134	129.0114	3.62302	0.534481	31.1641	18.6089	8.4402	4.482424	24.6513	Abnormal
38.69791	13.44475	31	25.25316	123.1593	1.429186	0.306581	28.3015	17.9575	14.75417	-14.2527	24.9361	Abnormal
41.72996	12.25407	30.12259	29.47589	116.5857	-1.2444	0.468526	28.5598	12.4637	14.1961	-20.3925	33.0265	Abnormal
43.92284	14.17796	37.83255	29.74488	134.461	6.451648	0.280446	12.4719	16.8965	10.32658	-4.98667	22.4667	Abnormal
54.91944	21.06233	42.2	33.85711	125.2127	2.432561	0.175245	23.0791	14.2195	14.14196	3.780394	24.9278	Abnormal
63.07361	24.4138	54	38.65981	106.4243	15.7797	0.666388	11.9696	17.6891	7.63771	-14.1836	44.2338	Abnormal

45.54079	13.0696	30.29832	32.47119	117.9808	-4.98713	0.56745	23.8889	9.1019	7.70987	-19.379	20.3649	Abnormal
.....												
46.2364	10.06277	37	36.17363	128.0636	-5.10005	0.860784	9.5912	15.1769	16.49989	-22.42	40.2061	Normal
46.42637	6.620795	48.1	39.80557	130.3501	2.449382	0.515439	9.1955	10.6369	15.11344	2.963625	23.0719	Normal
39.6569	16.20884	36.67486	23.44806	131.922	-4.96898	0.794717	31.3737	18.3533	13.16102	-6.65262	26.3297	Normal
45.57548	18.75914	33.77414	26.81635	116.797	3.13191	0.514212	24.2526	12.9572	12.40401	-12.3631	31.9668	Normal
66.50718	20.89767	31.72747	45.60951	128.9029	1.517203	0.787252	12.8877	11.8978	9.2322	-14.8244	43.8409	Normal
82.90535	29.89412	58.25054	53.01123	110.709	6.079338	0.827146	12.5622	12.3646	16.61754	-15.7588	35.9458	Normal
50.67668	6.461501	35	44.21518	116.588	-0.21471	0.021178	18.7846	8.007	9.74352	-1.2286	14.2547	Normal
89.01488	26.07598	69.02126	62.93889	111.4811	6.061508	0.544505	27.0219	13.3731	11.04819	-3.5053	33.4196	Normal
54.60032	21.48897	29.36022	33.11134	118.3433	-1.47107	0.962907	30.8554	11.4198	13.82322	-5.60645	18.5514	Normal
34.3823	2.062683	32.39082	32.31962	128.3002	-3.36552	0.581169	12.0774	16.6255	7.20496	-31.3748	29.5748	Normal
45.07545	12.30695	44.58318	32.7685	147.8946	-8.94171	0.932922	32.1169	14.3037	10.64326	-31.1988	11.2307	Normal
47.90357	13.61669	36	34.28688	117.4491	-4.2454	0.129744	7.8433	14.7484	8.51707	-15.7289	11.5472	Normal
53.93675	20.7215	29.22053	33.21525	114.3658	-0.42101	0.047913	19.1986	18.1972	7.08745	6.013843	43.8693	Normal
61.4466	22.69497	46.17035	38.75163	125.6707	-2.70788	0.08107	16.2059	13.5565	8.89572	3.564463	18.4151	Normal
45.25279	8.693157	41.58313	36.55963	118.5458	0.21475	0.159251	14.7334	16.0928	9.75922	5.767308	33.7192	Normal
33.84164	5.073991	36.64123	28.76765	123.9452	-0.19925	0.674504	19.3825	17.6963	13.72929	1.783007	40.6049	Normal

ДОДАТОК Б

Лістинг програми:

main.py

```
"""Entry point to evolving the neural network. Start here."""
from optimizer import Optimizer
from tqdm import tqdm
import pandas as pd
from pathlib import Path
import pickle
from datetime import datetime

# Number of networks to save to disk
SAVE_NET_NUM = 3
# % of networks to keep from previous generation
# There is no crossover chance, best parents will be kept with their childrens in p
urpose to avoid degenerating process
RETAIN = 0.3
# Chance of mutation
MUTATE_CHANCE = 0.2
# Chance that during mutation int\tuple variables will be changed to some value fro
m param list
# Used to add variance to algorithm and delay convergence (sometimes it's unnecessa
ry, but anyway).
RADICAL_MUTATE_CHANCE = 0.1

# Number of generations to run
GENERATIONS = 50
# Number of networks in each population
POPULATION = 60

def train_networks(networks, x, y):
    """Train each network.

    Args:
        networks (list): Current population of networks
        x (DataFrame): df of all collected data params
        y (DataFrame): df of same height with normal/abnormal classification of x
    """

    # Progress bar to display work of the program.
    pbar = tqdm(total=len(networks))
    # Train each network.
    for network in networks:
```

```

        network.train(x, y)
        pbar.update(1)
# Close progress bar.
pbar.close()

def get_average_accuracy(networks):
    """Get the average accuracy for a group of networks (calculated onle by best re
tained nets).

    Args:
        networks (list): List of networks

    Returns:
        float: The average accuracy of a population of networks.
    """

    total_accuracy = 0
    # Sort from best to worst, and get num of networks to save.
    sorted_net = sorted(networks, reverse=True, key=lambda x: x.accuracy)
    to_retain = int(len(sorted_net) * RETAIN)

    for network in sorted_net[:to_retain]:
        total_accuracy += network.accuracy
    # Get avg accuracy.
    return total_accuracy / to_retain

def generate(generations, population, nn_param_choices, x, y):
    """Generate a network with the genetic algorithm.

    Args:
        generations (int): Number of times to evolve the population
        population (int): Number of networks in each generation
        nn_param_choices (dict): Parameter choices for networks
        x (DataFrame): df of all collected data params
        y (DataFrame): df of same height with normal/abnormal classification of x
    Args example:
        x:
            Col11      Col12      Col3      Col4      Col5      Col6
        Col7      Col8      Col9      Col10     Col11     Col12
            0      63.027818  22.552586  39.609117  40.475232  98.672917  -
0.254400  0.744503  12.5661  14.5386  15.30468 -28.658501  43.5123
            2      33.841641  5.073991  36.641233  28.767649  123.945244  -
0.199249  0.674504  19.3825  17.6963  13.72929  1.783007  40.6049
            ..      ...      ...      ...      ...      ...      ...
            ...      ...      ...      ...      ...      ...

        y:
            0      Abnormal
            1      Normal

```

```

...

Returns:
    networks: the list of best networks.
"""

# I could use rollback to old generation (if new avg acc < new avg acc),
# but since code keeps the best networks "alive" and unchanged, result cannot go
down.
# Any light acc drop during the work of the program - result of non-
deterministic learning process of MLP.
optimizer = Optimizer(nn_param_choices, retain=RETAIN, mutate_chance=MUTATE_CHA
NCE, radical_mutate_chance=RADICAL_MUTATE_CHANCE)
networks = optimizer.create_population(population)

# Evolve the generation.
for i in range(generations):
    print("***Doing generation %d of %d***" % (i + 1, generations))
    # Train and get accuracy for networks.
    train_networks(networks, x, y)
    # Get the average accuracy for this generation.
    average_accuracy = get_average_accuracy(networks)
    # Print out the average accuracy each generation.
    print("Generation top average: %.2f%%" % (average_accuracy * 100))
    # Evolve, except on the last iteration.
    if i != generations - 1:
        # Do the evolution.
        networks = optimizer.evolve(networks)
    print('#'*80)

# Sort our final population.
networks = sorted(networks, key=lambda x: x.accuracy, reverse=True)

return networks

def print_networks(networks):
    """Print a list of networks.

    Args:
        networks (list): The population of networks
    """

    print('#'*80)

    for network in networks:
        network.print_network()

def get_data():
    """Prepares data from Dataset_spine.csv"""

```

```

df = pd.read_csv('Dataset_spine.csv')
# Drop dummy column.
df = df.drop(['Unnamed: 13'], axis=1)
# Rename columns according to: https://towardsdatascience.com/an-exploratory-data-analysis-on-lower-back-pain-6283d0b0123.
df.rename(columns={
    "Col1" : "pelvic_incidence",
    "Col2" : "pelvic_tilt",
    "Col3" : "lumbar_lordosis_angle",
    "Col4" : "sacral_slope",
    "Col5" : "pelvic_radius",
    "Col6" : "degree_spondylolisthesis",
    "Col7" : "pelvic_slope",
    "Col8" : "Direct_tilt",
    "Col9" : "thoracic_slope",
    "Col10" : "cervical_tilt",
    "Col11" : "sacrum_angle",
    "Col12" : "scoliosis_slope",
})
)
# Generate set of data and it's classification set for MLP.
y = df['Class_att']
x = df.drop(['Class_att'], axis=1)

return x, y

def save_networks(networks, dir_path = "./networks"):
    """Saves best networks to the disk."""

    Path(dir_path).mkdir(parents=True, exist_ok=True)

    for network in networks:
        file_name = f"{dir_path}/classifier_{datetime.today().strftime('%Y-%m-%d')}_acc{network.accuracy}.pkl"

        with open(file_name, 'wb') as fid:
            pickle.dump(network, fid)

def main():
    """Evolve a network."""

    if POPULATION < SAVE_NET_NUM:
        raise Exception("population number must be >= ", SAVE_NET_NUM)

    nn_param_choices = {
        "hidden_layer_sizes": [(12), (12, 12), (12,12,12),
                                (50), (50, 50), (50,50,50),

```

```

        (100), (100, 100), (100, 100, 100)],
        "max_iter": [6000, 7000, 8000, 9000],
        "alpha": [0.001, 0.0001, 0.00001],
        "solver": ['lbfgs', 'sgd', 'adam'], # The solver for weight optimization.
        "activation" : ['identity', 'logistic', 'tanh', 'relu'],
        "tol" : [1e-3, 1e-4, 1e-5, 1e-6],
    }

    print("***Evolving %d generations with population %d***" %
          (GENERATIONS, POPULATION))

    x, y = get_data()

    networks = generate(GENERATIONS, POPULATION, nn_param_choices, x, y)
    # Print out the top 5 networks.
    print_networks(networks[:SAVE_NET_NUM])
    save_networks(networks[:SAVE_NET_NUM])

if __name__ == '__main__':
    main()

```

network.py

```

"""Class that represents the network to be evolved."""
import random
import logging

from sklearn.neural_network import MLPClassifier
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
from sklearn.metrics import confusion_matrix

class Network():
    """Represent a network and let us operate on it.
    Currently only works for an MLP.
    """

    def __init__(self, nn_param_choices=None):
        """Initialize our network."""

        self.accuracy = 0.
        self.nn_param_choices = nn_param_choices
        self.network = {} # (dic): represents MLP network parameters.
        self.clf = None

    def create_random(self):
        """Create a random network."""

```



```

        for key in self.nn_param_choices:
            self.network[key] = random.choice(self.nn_param_choices[key])

    def create_set(self, network):
        """Set network properties.
        Args:
            network (dict): The network parameters
        """

        self.network = network

    def train(self, x, y):
        """Train the network and record the accuracy.
        Args:
            x (DataFrame): df of all collected data params
            y (DataFrame): df of same height with normal/abnormal classification of
x
        """

        # If model already trained - skip it.
        if self.accuracy != 0.:
            return
        # Create MLP classifier with given params.
        self.clf = MLPClassifier(**self.network)
        # Get datasets for training/testing, then train and test model.
        x_train, x_test, y_train, y_test = train_test_split(x,y, test_size= 0.25, r
andom_state=27)
        self.clf.fit(x_train, y_train)
        y_pred = self.clf.predict(x_test)
        # set curr model accuracy
        self.accuracy = accuracy_score(y_test, y_pred)

    def print_network(self):
        """Print out a network."""

        print(self.network)
        print("Network accuracy: %.2f%%" % (self.accuracy * 100))

```

optimizer.py

```

"""
Class that holds a genetic algorithm for evolving a network.
"""

from functools import reduce
from operator import add
import random

```

```

from network import Network

class Optimizer():
    """Class that implements genetic algorithm for MLP optimization."""

    def __init__(self, nn_param_choices, retain=0.4,
                  random_select=0.1, mutate_chance=0.25, radical_mutate_chance=0.1):
        """Create an optimizer.

        Args:
            nn_param_choices (dict): Possible network parameters
            retain (float): Percentage of population to retain after
                each generation
            random_select (float): Probability of a rejected network
                remaining in the population
            mutate_chance (float): Probability a network will be
                randomly mutated

        """

        self.mutate_chance = mutate_chance
        self.radical_mutate_chance = radical_mutate_chance
        self.random_select = random_select
        self.retain = retain
        self.nn_param_choices = nn_param_choices

    def create_population(self, count):
        """Create a population of random networks.

        Args:
            count (int): Number of networks to generate, aka the
                size of the population

        Returns:
            (list): Population of network objects

        """

        pop = []

        for _ in range(0, count):
            # Create a random network.
            network = Network(self.nn_param_choices)
            network.create_random()

            # Add the network to our population.
            pop.append(network)

        return pop

```

```

@staticmethod
def fitness(network):
    """Return the accuracy, which is our fitness function."""
    return network.accuracy

def grade(self, pop):
    """Find average fitness for a population.

    Args:
        pop (list): The population of networks

    Returns:
        (float): The average accuracy of the population

    """

    summed = reduce(add, (self.fitness(network) for network in pop))
    return summed / float((len(pop)))

def breed(self, mother, father):
    """Make two children as parts of their parents.

    Args:
        mother (dict): Network parameters
        father (dict): Network parameters

    Returns:
        (list): Two network objects

    """

    children = []
    for _ in range(2):

        child = {}

        # Loop through the parameters and pick params for the kid.
        for param in self.nn_param_choices:
            child[param] = random.choice(
                [mother.network[param], father.network[param]]
            )

        # Now create a network object.
        network = Network(self.nn_param_choices)
        network.create_set(child)

        # Randomly mutate some of the children.
        if self.mutate_chance > random.random():

```

```

        network = self.mutate(network)

        children.append(network)

    return children

def int_mutate(self, number, mutate_percent=10):
    """Mutates integer number up to mutate_percent from its initial value,
    as example, 10 could be mutated to a value from range [9:11].

    Args:
        number (int): Number to mutate.
        father (dict): Percent of the mutation.

    Returns:
        (int): Mutated number
    """

    percent = number * (mutate_percent/100)
    return random.randint(int(number - percent), int(number + percent))

def float_mutate(self, number, mutate_percent=15):
    """Mutates float number up to mutate_percent from its initial value.

    Args:
        number (float): Number to mutate.
        father (dict): Percent of the mutation.

    Returns:
        (float): Mutated number
    """

    percent = number * (mutate_percent/100)
    return random.uniform(number - percent, number + percent)

def random_layers(self, tuple_layers):
    """Mutates tuple that represents number of neurons in every layer of MLP.

    Args:
        tuple_layers (tuple): tuple that represents number of neurons in every
layer of MLP

    Returns:
        (tuple): Mutated tuple
    """

    mutated = []

    for layer_num in tuple_layers:

```

```

        mutated.append(self.int_mutate(layer_num))

    return tuple(mutated)

def mutate(self, network):
    """Randomly mutate one part of the network.

    Args:
        network (dict): The network parameters to mutate

    Returns:
        (Network): A randomly mutated network object

    """

    # Choose a random key.
    key = random.choice(list(self.nn_param_choices.keys()))
    val = network.network[key]
    # Mutate one of the params.
    if isinstance(val, tuple):
        # with a little chance - change the number of layers
        if random.random() > self.radical_mutate_chance:
            network.network[key] = self.random_layers(val)
        else:
            network.network[key] = random.choice(self.nn_param_choices[key])
    if isinstance(val, int):
        # Chance of radical mutation
        if random.random() > self.radical_mutate_chance:
            network.network[key] = self.int_mutate(val)
        else:
            network.network[key] = random.choice(self.nn_param_choices[key])
    if isinstance(val, float):
        if random.random() > self.radical_mutate_chance:
            network.network[key] = self.float_mutate(val)
        else:
            network.network[key] = random.choice(self.nn_param_choices[key])
    if isinstance(val, str):
        network.network[key] = random.choice(self.nn_param_choices[key])

    return network

def evolve(self, pop):
    """Evolve a population of networks.

    Args:
        pop (list): A list of network parameters

    Returns:
        (list): The evolved population of networks

```

```

"""

# Get scores for each network.
graded = [(self.fitness(network), network) for network in pop]
# Sort on the scores.
graded = [x[1] for x in sorted(graded, key=lambda x: x[0], reverse=True)]
# Get the number we want to keep for the next gen.
retain_length = int(len(graded)*self.retain)
# The parents are every network we want to keep.
parents = graded[:retain_length]

# For those we aren't keeping, randomly keep some anyway.
for individual in graded[retain_length:]:
    if self.random_select > random.random():
        parents.append(individual)

# Now find out how many spots we have left to fill.
parents_length = len(parents)
desired_length = len(pop) - parents_length
children = []

# Add children, which are bred from two remaining networks.
while len(children) < desired_length:
    self.born_childrens(parents, children, desired_length)

parents.extend(children)

return parents

def born_childrens(self, parents, children, desired_length):
    """Create childrens from given networks

    Args:
        parents (list): networks from wich childrens will be created
        children (list): list of childrens to extend
        desired_length (int): number of childrens to born
    """

    # Get a random mom and dad.
    male = random.randint(0, len(parents)-1)
    female = random.randint(0, len(parents)-1)

    # Assuming they aren't the same network...
    if male == female:
        return

    male = parents[male]
    female = parents[female]

```

```

# Breed them.
babies = self.breed(male, female)

# Add the children one at a time.
for baby in babies:
    # Don't grow larger than desired length.
    if len(children) >= desired_length:
        return

    children.append(baby)

```

test.py

```

import pandas as pd
import pickle
from network import Network

classifier = None

with open("networks/classifier_2021-01-08_acc0.8846153846153846.pkl", 'rb') as fid:
    classifier = pickle.load(fid)

df = pd.read_csv('Dataset_spine_test.csv')
# Drop dummy column.
df = df.drop(['Unnamed: 13'], axis=1)
# Rename columns according to: https://towardsdatascience.com/an-exploratory-data-analysis-on-lower-back-pain-6283d0b0123.
df.rename(columns={
    "Col1" : "pelvic_incidence",
    "Col2" : "pelvic_tilt",
    "Col3" : "lumbar_lordosis_angle",
    "Col4" : "sacral_slope",
    "Col5" : "pelvic_radius",
    "Col6" : "degree_spondylolisthesis",
    "Col7" : "pelvic_slope",
    "Col8" : "Direct_tilt",
    "Col9" : "thoracic_slope",
    "Col10" : "cervical_tilt",
    "Col11" : "sacrum_angle",
    "Col12" : "scoliosis_slope",
})
)

x_test = df.drop(['Class_att'], axis=1)
print(x_test)
y_pred = classifier.clf.predict(x_test)
print(y_pred)

```